

# Principle and Model

## 机器学习原理及模型入门

报告者：刘欣雨

2026 年 7 月 29 日

### 摘要

此报告没有复杂的数学公式，偏向于用易于理解的方式了解机器学习、深度学习以及强化学习。部分内容参考了吴恩达老师的《机器学习》课程精华。

## 目录

|          |                                        |          |
|----------|----------------------------------------|----------|
| <b>1</b> | <b>基本原理</b>                            | <b>3</b> |
| 1.1      | 机器学习是什么 . . . . .                      | 3        |
| 1.2      | 深度学习是什么 . . . . .                      | 3        |
| 1.3      | 强化学习是什么 . . . . .                      | 3        |
| 1.4      | 训练的过程 . . . . .                        | 4        |
| 1.5      | 前向传播 . . . . .                         | 4        |
| 1.6      | 反向传播 . . . . .                         | 4        |
| 1.7      | 收敛 . . . . .                           | 4        |
| 1.8      | 过拟合与欠拟合 . . . . .                      | 5        |
| 1.9      | 损失函数 . . . . .                         | 5        |
| 1.10     | 梯度下降 . . . . .                         | 5        |
| <b>2</b> | <b>基本模型</b>                            | <b>6</b> |
| 2.1      | 经典监督学习（Supervised Learning） . . . . .  | 6        |
| 2.1.1    | 1. 线性回归（Linear Regression） . . . . .   | 6        |
| 2.1.2    | 2. 逻辑回归（Logistic Regression） . . . . . | 6        |
| 2.1.3    | 3. 决策树（Decision Tree） . . . . .        | 6        |
| 2.1.4    | 4. 朴素贝叶斯（Naive Bayes） . . . . .        | 7        |
| 2.2      | 进阶监督学习 . . . . .                       | 7        |
| 2.2.1    | 5. 支持向量机（SVM） . . . . .                | 7        |

|       |                                   |    |
|-------|-----------------------------------|----|
| 2.2.2 | 6. 随机森林 (Random Forest)           | 7  |
| 2.2.3 | 7. 梯度提升 (Gradient Boosting)       | 8  |
| 2.3   | 无监督学习 (Unsupervised Learning)     | 8  |
| 2.3.1 | 8. K-Means 聚类                     | 8  |
| 2.3.2 | 9. 层次聚类 (Hierarchical Clustering) | 8  |
| 2.3.3 | 10. 主成分分析 (PCA)                   | 9  |
| 2.3.4 | 11. t-SNE                         | 9  |
| 2.4   | 神经网络 (Neural Network)             | 9  |
| 2.4.1 | 12. 多层感知机 (MLP)                   | 9  |
| 2.4.2 | 13. 卷积神经网络 (CNN)                  | 9  |
| 2.4.3 | 14. 循环神经网络 (RNN)                  | 10 |
| 2.5   | Transformer                       | 10 |
| 2.5.1 | 15. 自注意力机制 (Self-Attention)       | 10 |
| 2.5.2 | 16. 多头注意力 (Multi-Head Attention)  | 10 |
| 2.5.3 | 17. BERT 与 GPT                    | 10 |
| 2.5.4 | 18. ViT (Vision Transformer)      | 11 |
| 2.6   | 生成模型 (Generative Models)          | 11 |
| 2.6.1 | 19. 生成对抗网络 (GAN)                  | 11 |
| 2.6.2 | 20. 变分自编码器 (VAE)                  | 11 |
| 2.6.3 | 21. 扩散模型 (Diffusion Model)        | 11 |
| 2.7   | 强化学习 (Reinforcement Learning)     | 12 |
| 2.7.1 | 22. Q-Learning                    | 12 |
| 2.7.2 | 23. 深度强化学习 (DRL)                  | 12 |
| 2.7.3 | 24. AutoGPT / 自主 Agent            | 12 |
| 2.8   | 优化与评估                             | 12 |
| 2.8.1 | 25. 交叉验证 (Cross Validation)       | 12 |
| 2.8.2 | 26. 超参数调优 (Hyperparameter Tuning) | 13 |
| 2.8.3 | 27. 特征工程 (Feature Engineering)    | 13 |

## 第1部分： 基本原理

### 1.1 机器学习是什么

#### 一句话解释

机器学习就是让计算机从数据中”学”出规律，而不是靠人一条一条写规则。

想象一下，你怎么教一个三岁小孩认”猫”？你不会给他写一本《猫的特征手册》（两条腿、有尾巴、会喵叫……），你只是不断地给他看猫的图片，说”这是猫”，看多了，他自己就学会了。机器学习也是这个道理——给它大量数据，它自己找规律。

吴恩达老师有个经典定义：机器学习是”让计算机在没有明确编程的情况下拥有学习能力”的学科。简单说，不是写代码告诉它怎么做，而是给它数据让它自己悟。

### 1.2 深度学习是什么

#### 一句话解释

深度学习是机器学习的一个分支，用”很多层”的神经网络来提取特征，层数越深越”深”。

如果把机器学习比作一条生产线，那深度学习就是一条**多层筛选流水线**：第一层筛选出边缘和颜色，第二层筛选出纹理和形状，第三层组合出猫耳朵和猫脸……每一层都在上一层的输出上进一步加工，层层递进，最终识别出”这是一只猫”。这就是”深度”的含义——不是思想深刻，而是**网络层数多**。

### 1.3 强化学习是什么

#### 一句话解释

强化学习是让智能体通过”试错 + 奖励”来学习最优策略。

你训练小狗做动作时怎么做？坐下了给零食，乱跑就不给。小狗慢慢学会了”坐下有肉吃”。**强化学习就是”训练小狗”的数学版**——智能体在环境里不断尝试，做对了拿奖励，做错了扣分，最终学会在什么情况下做什么动作能拿最多的奖励。

## 1.4 训练的过程

### 一句话解释

训练 = 做题 → 对答案 → 调整方法，反复循环直到正确率满意为止。

就像你做数学题：先用当前的方法算一遍（前向传播），然后对标准答案看差多少（算损失），再根据差距调整自己的解题思路（反向传播 + 参数更新）。每做一轮就是一步训练，做得越多，方法越好——当然前提是方法别跑偏。

## 1.5 前向传播

### 一句话解释

数据从输入层一路流到输出层，每经过一层就算一次，最终得到预测结果。

就像流水线上产品从第一道工序流向最后一道工序，信息在网络里也是从前往后一路流过去，中间没有回头路。输入图片像素 → 第一层提取边缘 → 第二层组合纹理 → …… → 最后一层输出”这是猫的概率 = 0.93”。这个从输入到输出的单向计算过程，就叫前向传播。

## 1.6 反向传播

### 一句话解释

从最终误差倒着往回算，找出每一层该背多少”锅”，然后调整参数。

假如预测结果说”这是猫 0.93”但实际是狗，那误差出在哪？反向传播就是从结果倒推，找出谁的锅——最后一层的权重贡献了多少误差？倒数第二层呢？一层一层往回追责，搞清楚每个参数该负多少责任，然后相应地调整它。这就是神经网络能”学习”的核心机制。

## 1.7 收敛

### 一句话解释

训练过程中，损失越来越小，最终稳定下来不再大幅波动，就是”收敛”了。

想象你蒙着眼在山里往下走，一开始跌跌撞撞，后来越走越稳，最终站在一个谷底不动了——这个”摇摇晃晃最终站稳”的过程就是收敛。不过要注意，你可能站在的是一个坑（局部最优）而不是最低的大谷底（全局最优），这正是优化算法要解决的难题。

## 1.8 过拟合与欠拟合

### 一句话解释

过拟合 = 死记硬背，考试题都会但换个题就傻眼；欠拟合 = 压根没学，啥也不会。

- **过拟合**：模型把训练数据的每个细节都记住了，连噪声都背下来。就像一个学生把历年真题答案全背了，遇到新题就懵圈。
- **欠拟合**：模型太简单，连训练数据的规律都没学出来。就像上课全程走神，连基本概念都没掌握。

好模型应该在两者之间——既学到规律，又不死记硬背。吴恩达老师建议用训练集和验证集的误差对比来判断：训练集好但验证集差 → 过拟合；两个都差 → 欠拟合。

## 1.9 损失函数

### 一句话解释

损失函数就是“考试打分”，分越低说明预测越准，我们训练的目标就是让这个分数尽量低。

你考了 80 分，同学考了 95 分，谁的损失更小？当然是 95 分的。损失函数就是在衡量“预测值和真实值差多少”。常见的有均方误差（MSE）用于回归、交叉熵用于分类。训练的全部目的，就是让损失函数的值尽量小。

## 1.10 梯度下降

### 一句话解释

蒙着眼下山，脚探一探，哪边低就往哪走一步，走到底就是山谷。

梯度下降是最核心的优化方法。想象你被蒙住眼扔到一座山上，要走到谷底。你只能用脚探一探周围，感受哪边坡度往下，就往那个方向迈一步。**梯度就是坡度的方向和大小**，学习率就是你每一步迈多大——步子太大可能跨过谷底，步子太小走得太慢。选择合适的学习率至关重要。

## 第2部分： 基本模型

### 2.1 经典监督学习（Supervised Learning）

监督学习的核心：**有老师教**——每个训练样本都带着标准答案（标签），模型照着答案学。

#### 2.1.1 1. 线性回归（Linear Regression）

##### Linear Regression

**一句话：**用一条直线去拟合数据，预测连续数值。

**场景：**根据房屋面积预测房价，根据学习时长预测分数，根据广告投入预测销量。

**指标：**MSE（均方误差）——预测值和真实值差的平方的平均； $R^2$ ——模型解释了多少数据的变化。

**对比：**是所有回归模型的起点，逻辑回归就是在它基础上把输出压到 0 到 1 之间。

#### 2.1.2 2. 逻辑回归（Logistic Regression）

##### Logistic Regression

**一句话：**虽然叫“回归”，但其实是个分类器，用 sigmoid 函数把输出压到 0~1 之间当概率用。

**场景：**判断邮件是否垃圾邮件、判断肿瘤是否恶性、判断用户是否会点击广告。

**指标：**准确率、F1 分数（精确率和召回率的调和平均）、AUC-ROC（分类阈值变化时整体表现的衡量）。

**对比：**线性回归预测连续值，逻辑回归预测概率做分类；本质上就是线性回归外面套了个 sigmoid。

#### 2.1.3 3. 决策树（Decision Tree）

##### Decision Tree

**一句话：**像玩“20 个问题”游戏一样，通过一系列判断条件一步步缩小范围，最终得出结论。

**场景：**贷款审批（收入 >5 万？→ 有房？→ ...）、医疗辅助诊断、客户流失预测。

**指标：**基尼系数（越小说明分得越纯）、信息熵（衡量混乱程度，越纯越小）。

**对比：**与线性模型不同，决策树天然能处理非线性关系和特征交互，可解释性强，但容易过拟合。

### 2.1.4 4. 朴素贝叶斯 (Naive Bayes)

#### Naive Bayes

**一句话：**基于贝叶斯定理，假设各特征之间相互独立（“朴素”就在这），算出属于各类别的概率。

**场景：**垃圾邮件过滤（“免费”“优惠”出现 → 垃圾概率高）、文本分类、情感分析。

**指标：**准确率、F1 分数。

**对比：**逻辑回归是直接学决策边界，朴素贝叶斯是先学概率分布再做决策；朴素贝叶斯训练更快，逻辑回归通常精度更高。

## 2.2 进阶监督学习

### 2.2.1 5. 支持向量机 (SVM)

#### SVM

**一句话：**找一条最“宽”的分界线把两类数据分开，让离边界最近的点（支持向量）尽可能远离分界线。

**场景：**图像分类、文本分类、小样本下的高维分类问题。

**指标：**准确率、F1 分数。

**对比：**逻辑回归追求所有点都对，SVM 只关心边界附近的点——所以 SVM 在高维小样本时往往更鲁棒。

### 2.2.2 6. 随机森林 (Random Forest)

#### Random Forest

**一句话：**建一堆各自有点不同的决策树，每棵树独立投票，少数服从多数——“三个臭皮匠，顶个诸葛亮”。

**场景：**特征多的大数据集、金融风控、电商推荐、医疗诊断。

**指标：**OOB 误差（袋外估计，自带验证集）、准确率。

**对比：**单棵决策树容易过拟合，随机森林通过“多棵树投票 + 随机选特征”大幅降低过拟合风险。

### 2.2.3 7. 梯度提升 (Gradient Boosting)

#### Gradient Boosting

**一句话：**一棵树先粗略拟合，下一棵树专门拟合上一棵的残差，一棵接一棵”接力纠错”。

**场景：**Kaggle 竞赛常胜将军、表格数据分析、搜索排序、保险定价。

**指标：**准确率、NDCG（归一化折损累积增益，衡量排序质量）。

**对比：**随机森林是”并行投票”，梯度提升是”串行纠错”——后者通常精度更高但更容易过拟合，需要仔细调参。

## 2.3 无监督学习 (Unsupervised Learning)

无监督学习：没有标准答案，模型自己从数据中找结构、找模式。

### 2.3.1 8. K-Means 聚类

#### K-Means

**一句话：**事先定好要分 K 个群，随机放 K 个中心点，然后把每个数据点归到最近的中心，再更新中心位置，反复迭代直到稳定。

**场景：**客户分群（高消费/低消费/潜在客户）、图像压缩、异常检测。

**指标：**轮廓系数（衡量聚类紧密度和分离度）、SSE（簇内误差平方和，越小越紧凑）。

### 2.3.2 9. 层次聚类 (Hierarchical Clustering)

#### Hierarchical Clustering

**一句话：**从每个点各成一个簇开始，不断把最近的两个簇合并，最终形成一棵”族谱树”。

**场景：**物种分类、基因聚类、组织架构分析。

**指标：**树状图（Dendrogram，可视化聚类过程和层次关系）。

**对比：**K-Means 需要预先指定 K，层次聚类不需要；层次聚类结果可解释但计算量大，K-Means 快但只能找球形簇。



### 2.3.3 10. 主成分分析 (PCA)

#### PCA

**一句话：**找到数据变化最大的方向，把高维数据投影到这些方向上，用更少的维度保留最多的信息。

**场景：**降维后可视化（把 100 维数据压到 2 维画图）、加速训练、去噪。

**指标：**方差解释率（各主成分保留了多少原始数据的方差/信息量）。

### 2.3.4 11. t-SNE

#### t-SNE

**一句话：**一种专门为可视化设计的降维方法，让高维中相近的点在 2D/3D 中也挨在一起。

**场景：**高维数据可视化（手写数字、基因表达数据的 2D 展示）。

**指标：**视觉分离度——看图上不同类别是否分得开。

**对比：**PCA 是线性降维，保留全局结构；t-SNE 是非线性降维，保留局部邻居关系，可视化效果好但不能用于特征提取。

## 2.4 神经网络 (Neural Network)

### 2.4.1 12. 多层感知机 (MLP)

#### MLP

**一句话：**逻辑回归加了隐藏层，隐藏层能学到非线性的特征组合。

**场景：**通用非线性分类/回归、表格数据的深度学习基线。

**对比：**就是“加了隐藏层的逻辑回归”——没有隐藏层时退化为逻辑回归，加了隐藏层后就能学习复杂的非线性决策边界。

### 2.4.2 13. 卷积神经网络 (CNN)

#### CNN

**一句话：**用“滑动窗口”在图像上扫来扫去，每次只看一小块区域，提取局部特征（边缘、纹理等）。

**场景：**图像分类、目标检测、人脸识别、医学影像分析。

**为什么适合图像：**图像的局部像素关联很强（猫耳朵的像素挨在一起），CNN 用小窗口滑动，天然适合提取这种局部特征，而且参数共享大大减少了参数量。

### 2.4.3 14. 循环神经网络 (RNN)

#### RNN

**一句话：**有”记忆”的网络，处理当前输入时会参考之前看到的信息。

**场景：**文本生成、机器翻译、语音识别、股票时序预测。

**为什么适合序列：**句子中每个词的含义取决于上下文，RNN 的隐状态就像一个不断更新的”笔记本”，记录了之前看过的内容，所以适合处理有先后顺序的数据。不过标准 RNN 记忆很短，后来 LSTM 和 GRU 解决了这个问题。

## 2.5 Transformer

### 2.5.1 15. 自注意力机制 (Self-Attention)

#### Self-Attention

**一句话：**每个词都看看句子中其他词在干嘛，决定自己该关注谁、关注多少。

比如”这只猫很可爱，它喜欢睡觉”中的”它”，需要注意到”猫”才能知道”它”指代什么。自注意力机制让每个位置都能直接和其他位置”对话”，不用像 RNN 那样一步步传信息。

### 2.5.2 16. 多头注意力 (Multi-Head Attention)

#### Multi-Head Attention

**一句话：**多组”视角”同时看——有的头关注语法关系，有的关注语义相似，有的关注位置远近，最后把各头的发现汇总。

就像你看一幅画，有人看构图，有人看色彩，有人看细节，每个人角度不同但合起来理解更全面。

### 2.5.3 17. BERT 与 GPT

#### BERT & GPT

**BERT：**双向编码器，同时看上下文两边。预训练任务是”完形填空”——随机遮住一些词，让模型根据上下文猜被遮的词。擅长理解语义，适合分类、问答、匹配等任务。

**GPT：**单向解码器，只看上文（从左到右）。预训练任务是”续写作文”——根据前文预测下一个词。擅长生成文本，适合对话、写作、代码生成等任务。

**一句话区别：**BERT 是”完形填空高手”，GPT 是”续写作文能手”。

### 2.5.4 18. ViT (Vision Transformer)

#### ViT

**一句话：**把图片切成一个个小方块（patch），把每个小方块当作一个“词”，然后像处理文本一样用 Transformer 处理。

为什么能行？因为注意力机制不在乎输入是文字还是图片像素，只要切成序列就行。数据量够大时，ViT 甚至超越了传统 CNN。

## 2.6 生成模型 (Generative Models)

### 2.6.1 19. 生成对抗网络 (GAN)

#### GAN

**一句话：**两个网络对抗训练——生成器负责造假，判别器负责验真，互相博弈，最终生成器造的假货连判别器都认不出。

**场景：**生成逼真的人脸、图像超分辨率、风格迁移、数据增强。

**类比：**就像造假币的 vs 验钞机，假币越做越真，验钞机越来越厉害，双方共同进步。

### 2.6.2 20. 变分自编码器 (VAE)

#### VAE

**一句话：**把数据压缩到一个有规律的潜在空间里，再从潜在空间还原回来，压缩 + 重建 = 学会数据分布。

**场景：**图像生成、数据压缩与重建、药物分子生成。

**对比：**GAN 生成的图像更锐利但训练不稳定；VAE 生成更模糊但训练稳定，且潜在空间有良好的数学结构，可以插值生成中间状态。

### 2.6.3 21. 扩散模型 (Diffusion Model)

#### Diffusion Model

**一句话：**先给图片不断加噪直到变成纯噪点，然后训练网络学会一步步把噪点去掉，从噪点中慢慢还原图像。

**场景：**AI 画图（Stable Diffusion、DALL·E、Midjourney）。

**类比：**就像你把一滴墨水滴进水里扩散开，扩散模型学会“倒放这个过程”——从均匀的浑水中一点一点把墨滴“收”回来。

## 2.7 强化学习 (Reinforcement Learning)

### 2.7.1 22. Q-Learning

#### Q-Learning

**一句话：**维护一张“记分牌”（Q 表），记录在每个状态下做每个动作能拿多少分，选分数最高的动作就行。

**场景：**简单游戏的 AI、机器人路径规划、迷宫求解。

**类比：**就像你记住了“在这个路口左转能拿 10 分，右转能拿 5 分”，下次到这个路口你就左转。

### 2.7.2 23. 深度强化学习 (DRL)

#### DRL

**一句话：**状态太多 Q 表存不下？用神经网络代替 Q 表，输入状态，输出每个动作的 Q 值。

**场景：**Atari 游戏、围棋（AlphaGo）、自动驾驶决策。

**对比：**Q-Learning 用表格存分数，DRL 用神经网络“猜”分数——状态空间巨大时表格不现实，神经网络可以泛化到没见过的状态。

### 2.7.3 24. AutoGPT / 自主 Agent

#### AutoGPT

**一句话：**让大语言模型自己设定目标、自己拆解任务、自己调用工具、自己评估结果，尽量减少人类干预。

**场景：**自动调研写报告、自主编程调试、连续执行多步骤任务。

**注意：**目前自主 Agent 还很不成熟，经常跑偏或陷入循环，但这是 AI 发展的重要方向——从“你问我答”变成“我帮你做”。

## 2.8 优化与评估

### 2.8.1 25. 交叉验证 (Cross Validation)

#### Cross Validation

**一句话：**把数据分成几份，轮流拿一份当测试集、其余当训练集，多次考试取平均，避免一次考好就膨胀。

**最常用的是 K 折交叉验证：**把数据分成 K 份，做 K 次训练和验证，取 K 次结果的平均。这样评估结果更可靠，不会因为数据划分的运气成分而偏差太大。

### 2.8.2 26. 超参数调优 (Hyperparameter Tuning)

#### Hyperparameter Tuning

**一句话：**调模型的各种”旋钮”（学习率、树的数量、正则化强度等），找到最佳画面。

**类比：**就像调老电视的旋钮——亮度、对比度、色调，每个旋钮转一点画面就变，要耐心地调到最佳效果。常见方法有网格搜索（每个旋钮转一圈试一遍）、随机搜索（随机转几次碰运气）、贝叶斯优化（根据之前的结果猜下一个好位置）。

### 2.8.3 27. 特征工程 (Feature Engineering)

#### Feature Engineering

**一句话：**在把数据喂给模型之前，先把”食材”切好、配好、选好，让模型更容易学。

**类比：**就像做饭——同样的原材料，切配方式不同，做出来的味道天差地别。特征工程包括：特征选择（扔掉没用的食材）、特征构造（把两种食材组合出新味道）、特征缩放（统一量纲，别让盐和水的量级差距太大）。

在传统机器学习中，特征工程做得好，比模型选得花哨更重要。