

Principle and Model

机器学习原理及模型入门

报告者：刘欣雨

2026 年 8 月 1 日

摘要

此报告没有复杂的数学公式，偏向于用易于理解的方式了解机器学习、深度学习以及强化学习。部分内容参考了吴恩达老师的《机器学习》课程精华。

目录

1	基本原理	2
1.1	机器学习是什么	2
1.2	深度学习是什么	2
1.3	强化学习是什么	2
1.4	训练的过程	3
1.5	前向传播	3
1.6	反向传播	3
1.7	收敛	3
1.8	过拟合与欠拟合	4
1.9	损失函数	4
1.10	梯度下降	4
2	基本模型	5
2.1	经典监督学习（Supervised Learning）	5
2.1.1	1. 线性回归（Linear Regression）	5
2.1.2	2. 逻辑回归（Logistic Regression）	5
2.1.3	3. 决策树（Decision Tree）	5
2.1.4	4. 朴素贝叶斯（Naive Bayes）	6
2.2	进阶监督学习	6
2.2.1	5. 支持向量机（SVM）	6

2.2.2	6. 随机森林 (Random Forest)	6
2.2.3	7. 梯度提升 (Gradient Boosting)	7
2.3	无监督学习 (Unsupervised Learning)	7
2.3.1	8. K-Means 聚类	7
2.3.2	9. 层次聚类 (Hierarchical Clustering)	7
2.3.3	10. 主成分分析 (PCA)	8
2.3.4	11. t-SNE	8
2.4	神经网络 (Neural Network)	8
2.4.1	12. 多层感知机 (MLP)	8
2.4.2	13. 卷积神经网络 (CNN)	8
2.4.3	14. 循环神经网络 (RNN)	9
2.5	Transformer	9
2.5.1	15. 自注意力机制 (Self-Attention)	9
2.5.2	16. 多头注意力 (Multi-Head Attention)	9
2.5.3	17. BERT 与 GPT	9
2.5.4	18. ViT (Vision Transformer)	10
2.6	生成模型 (Generative Models)	10
2.6.1	19. 生成对抗网络 (GAN)	10
2.6.2	20. 变分自编码器 (VAE)	10
2.6.3	21. 扩散模型 (Diffusion Model)	10
2.7	强化学习 (Reinforcement Learning)	11
2.7.1	22. Q-Learning	11
2.7.2	23. 深度强化学习 (DRL)	11
2.7.3	24. AutoGPT / 自主 Agent	11
2.8	优化与评估	11
2.8.1	25. 交叉验证 (Cross Validation)	11
2.8.2	26. 超参数调优 (Hyperparameter Tuning)	12
2.8.3	27. 特征工程 (Feature Engineering)	12

第1部分： 基本原理

1.1 机器学习是什么

一句话解释

机器学习就是让计算机从数据中”学”出规律，而不是靠人一条一条写规则。

想象一下，你怎么教一个三岁小孩认”猫”？你不会给他写一本《猫的特征手册》（两条腿、有尾巴、会喵叫……），你只是不断地给他看猫的图片，说”这是猫”，看多了，他自己就学会了。机器学习也是这个道理——给它大量数据，它自己找规律。

吴恩达老师有个经典定义：机器学习是”让计算机在没有明确编程的情况下拥有学习能力”的学科。简单说，不是写代码告诉它怎么做，而是给它数据让它自己悟。

1.2 深度学习是什么

一句话解释

深度学习是机器学习的一个分支，用”很多层”的神经网络来提取特征，层数越深越”深”。

如果把机器学习比作一条生产线，那深度学习就是一条**多层筛选流水线**：第一层筛选出边缘和颜色，第二层筛选出纹理和形状，第三层组合出猫耳朵和猫脸……每一层都在上一层的输出上进一步加工，层层递进，最终识别出”这是一只猫”。这就是”深度”的含义——不是思想深刻，而是**网络层数多**。

1.3 强化学习是什么

一句话解释

强化学习是让智能体通过”试错 + 奖励”来学习最优策略。

你训练小狗做动作时怎么做？坐下了给零食，乱跑就不给。小狗慢慢学会了”坐下有肉吃”。**强化学习就是”训练小狗”的数学版**——智能体在环境里不断尝试，做对了拿奖励，做错了扣分，最终学会在什么情况下做什么动作能拿最多的奖励。

1.4 训练的过程

一句话解释

训练 = 做题 → 对答案 → 调整方法，反复循环直到正确率满意为止。

就像你做数学题：先用当前的方法算一遍（前向传播），然后对标准答案看差多少（算损失），再根据差距调整自己的解题思路（反向传播 + 参数更新）。每做一轮就是一步训练，做得越多，方法越好——当然前提是方法别跑偏。

1.5 前向传播

一句话解释

数据从输入层一路流到输出层，每经过一层就算一次，最终得到预测结果。

就像流水线上产品从第一道工序流向最后一道工序，信息在网络里也是从前往后一路流过去，中间没有回头路。输入图片像素 → 第一层提取边缘 → 第二层组合纹理 → …… → 最后一层输出”这是猫的概率 = 0.93”。这个从输入到输出的单向计算过程，就叫前向传播。

1.6 反向传播

一句话解释

从最终误差倒着往回算，找出每一层该背多少”锅”，然后调整参数。

假如预测结果说”这是猫 0.93”但实际是狗，那误差出在哪？反向传播就是从结果倒推，找出谁的锅——最后一层的权重贡献了多少误差？倒数第二层呢？一层一层往回追责，搞清楚每个参数该负多少责任，然后相应地调整它。这就是神经网络能”学习”的核心机制。

1.7 收敛

一句话解释

训练过程中，损失越来越小，最终稳定下来不再大幅波动，就是”收敛”了。

想象你蒙着眼在山里往下走，一开始跌跌撞撞，后来越走越稳，最终站在一个谷底不动了——这个”摇摇晃晃最终站稳”的过程就是收敛。不过要注意，你可能站在的是一个坑（局部最优）而不是最低的大谷底（全局最优），这正是优化算法要解决的难题。

1.8 过拟合与欠拟合

一句话解释

过拟合 = 死记硬背，考试题都会但换个题就傻眼；欠拟合 = 压根没学，啥也不会。

- **过拟合**：模型把训练数据的每个细节都记住了，连噪声都背下来。就像一个学生把历年真题答案全背了，遇到新题就懵圈。
- **欠拟合**：模型太简单，连训练数据的规律都没学出来。就像上课全程走神，连基本概念都没掌握。

好模型应该在两者之间——既学到规律，又不死记硬背。吴恩达老师建议用训练集和验证集的误差对比来判断：训练集好但验证集差 → 过拟合；两个都差 → 欠拟合。

1.9 损失函数

一句话解释

损失函数就是“考试打分”，分越低说明预测越准，我们训练的目标就是让这个分数尽量低。

你考了 80 分，同学考了 95 分，谁的损失更小？当然是 95 分的。损失函数就是在衡量“预测值和真实值差多少”。常见的有均方误差（MSE）用于回归、交叉熵用于分类。训练的全部目的，就是让损失函数的值尽量小。

1.10 梯度下降

一句话解释

蒙着眼下山，脚探一探，哪边低就往哪走一步，走到底就是山谷。

梯度下降是最核心的优化方法。想象你被蒙住眼扔到一座山上，要走到谷底。你只能用脚探一探周围，感受哪边坡度往下，就往那个方向迈一步。**梯度就是坡度的方向和大小**，学习率就是你每一步迈多大——步子太大可能跨过谷底，步子太小走得太慢。选择合适的学习率至关重要。

第2部分： 基本模型

2.1 经典监督学习（Supervised Learning）

监督学习的核心：**有老师教**——每个训练样本都带着标准答案（标签），模型照着答案学。

2.1.1 1. 线性回归（Linear Regression）

Linear Regression

一句话：用一条直线去拟合数据，预测连续数值。

场景：根据房屋面积预测房价，根据学习时长预测分数，根据广告投入预测销量。

指标：MSE（均方误差）——预测值和真实值差的平方的平均； R^2 ——模型解释了多少数据的变化。

对比：是所有回归模型的起点，逻辑回归就是在它基础上把输出压到 0 到 1 之间。

2.1.2 2. 逻辑回归（Logistic Regression）

Logistic Regression

一句话：虽然叫“回归”，但其实是个分类器，用 sigmoid 函数把输出压到 0~1 之间当概率用。

场景：判断邮件是否垃圾邮件、判断肿瘤是否恶性、判断用户是否会点击广告。

指标：准确率、F1 分数（精确率和召回率的调和平均）、AUC-ROC（分类阈值变化时整体表现的衡量）。

对比：线性回归预测连续值，逻辑回归预测概率做分类；本质上就是线性回归外面套了个 sigmoid。

2.1.3 3. 决策树（Decision Tree）

Decision Tree

一句话：像玩“20 个问题”游戏一样，通过一系列判断条件一步步缩小范围，最终得出结论。

场景：贷款审批（收入 >5 万？→ 有房？→ ...）、医疗辅助诊断、客户流失预测。

指标：基尼系数（越小说明分得越纯）、信息熵（衡量混乱程度，越纯越小）。

对比：与线性模型不同，决策树天然能处理非线性关系和特征交互，可解释性强，但容易过拟合。

2.1.4 4. 朴素贝叶斯 (Naive Bayes)

Naive Bayes

一句话：基于贝叶斯定理，假设各特征之间相互独立（“朴素”就在这），算出属于各类别的概率。

场景：垃圾邮件过滤（“免费”“优惠”出现 → 垃圾概率高）、文本分类、情感分析。

指标：准确率、F1 分数。

对比：逻辑回归是直接学决策边界，朴素贝叶斯是先学概率分布再做决策；朴素贝叶斯训练更快，逻辑回归通常精度更高。

2.2 进阶监督学习

2.2.1 5. 支持向量机 (SVM)

SVM

一句话：找一条最“宽”的分界线把两类数据分开，让离边界最近的点（支持向量）尽可能远离分界线。

场景：图像分类、文本分类、小样本下的高维分类问题。

指标：准确率、F1 分数。

对比：逻辑回归追求所有点都对，SVM 只关心边界附近的点——所以 SVM 在高维小样本时往往更鲁棒。

2.2.2 6. 随机森林 (Random Forest)

Random Forest

一句话：建一堆各自有点不同的决策树，每棵树独立投票，少数服从多数——“三个臭皮匠，顶个诸葛亮”。

场景：特征多的大数据集、金融风控、电商推荐、医疗诊断。

指标：OOB 误差（袋外估计，自带验证集）、准确率。

对比：单棵决策树容易过拟合，随机森林通过“多棵树投票 + 随机选特征”大幅降低过拟合风险。

2.2.3 7. 梯度提升 (Gradient Boosting)

Gradient Boosting

一句话：一棵树先粗略拟合，下一棵树专门拟合上一棵的残差，一棵接一棵”接力纠错”。

场景：Kaggle 竞赛常胜将军、表格数据分析、搜索排序、保险定价。

指标：准确率、NDCG（归一化折损累积增益，衡量排序质量）。

对比：随机森林是”并行投票”，梯度提升是”串行纠错”——后者通常精度更高但更容易过拟合，需要仔细调参。

2.3 无监督学习 (Unsupervised Learning)

无监督学习：没有标准答案，模型自己从数据中找结构、找模式。

2.3.1 8. K-Means 聚类

K-Means

一句话：事先定好要分 K 个群，随机放 K 个中心点，然后把每个数据点归到最近的中心，再更新中心位置，反复迭代直到稳定。

场景：客户分群（高消费/低消费/潜在客户）、图像压缩、异常检测。

指标：轮廓系数（衡量聚类紧密度和分离度）、SSE（簇内误差平方和，越小越紧凑）。

2.3.2 9. 层次聚类 (Hierarchical Clustering)

Hierarchical Clustering

一句话：从每个点各成一个簇开始，不断把最近的两个簇合并，最终形成一棵”族谱树”。

场景：物种分类、基因聚类、组织架构分析。

指标：树状图（Dendrogram，可视化聚类过程和层次关系）。

对比：K-Means 需要预先指定 K，层次聚类不需要；层次聚类结果可解释但计算量大，K-Means 快但只能找球形簇。

2.3.3 10. 主成分分析 (PCA)

PCA

一句话：找到数据变化最大的方向，把高维数据投影到这些方向上，用更少的维度保留最多的信息。

场景：降维后可视化（把 100 维数据压到 2 维画图）、加速训练、去噪。

指标：方差解释率（各主成分保留了多少原始数据的方差/信息量）。

2.3.4 11. t-SNE

t-SNE

一句话：一种专门为可视化设计的降维方法，让高维中相近的点在 2D/3D 中也挨在一起。

场景：高维数据可视化（手写数字、基因表达数据的 2D 展示）。

指标：视觉分离度——看图上不同类别是否分得开。

对比：PCA 是线性降维，保留全局结构；t-SNE 是非线性降维，保留局部邻居关系，可视化效果好但不能用于特征提取。

2.4 神经网络 (Neural Network)

2.4.1 12. 多层感知机 (MLP)

MLP

一句话：逻辑回归加了隐藏层，隐藏层能学到非线性的特征组合。

场景：通用非线性分类/回归、表格数据的深度学习基线。

对比：就是“加了隐藏层的逻辑回归”——没有隐藏层时退化为逻辑回归，加了隐藏层后就能学习复杂的非线性决策边界。

2.4.2 13. 卷积神经网络 (CNN)

CNN

一句话：用“滑动窗口”在图像上扫来扫去，每次只看一小块区域，提取局部特征（边缘、纹理等）。

场景：图像分类、目标检测、人脸识别、医学影像分析。

为什么适合图像：图像的局部像素关联很强（猫耳朵的像素挨在一起），CNN 用小窗口滑动，天然适合提取这种局部特征，而且参数共享大大减少了参数量。

2.4.3 14. 循环神经网络 (RNN)

RNN

一句话：有”记忆”的网络，处理当前输入时会参考之前看到的信息。

场景：文本生成、机器翻译、语音识别、股票时序预测。

为什么适合序列：句子中每个词的含义取决于上下文，RNN 的隐状态就像一个不断更新的”笔记本”，记录了之前看过的内容，所以适合处理有先后顺序的数据。不过标准 RNN 记忆很短，后来 LSTM 和 GRU 解决了这个问题。

2.5 Transformer

2.5.1 15. 自注意力机制 (Self-Attention)

Self-Attention

一句话：每个词都看看句子中其他词在干嘛，决定自己该关注谁、关注多少。

比如”这只猫很可爱，它喜欢睡觉”中的”它”，需要注意到”猫”才能知道”它”指代什么。自注意力机制让每个位置都能直接和其他位置”对话”，不用像 RNN 那样一步步传信息。

2.5.2 16. 多头注意力 (Multi-Head Attention)

Multi-Head Attention

一句话：多组”视角”同时看——有的头关注语法关系，有的关注语义相似，有的关注位置远近，最后把各头的发现汇总。

就像你看一幅画，有人看构图，有人看色彩，有人看细节，每个人角度不同但合起来理解更全面。

2.5.3 17. BERT 与 GPT

BERT & GPT

BERT：双向编码器，同时看上下文两边。预训练任务是”完形填空”——随机遮住一些词，让模型根据上下文猜被遮的词。擅长理解语义，适合分类、问答、匹配等任务。

GPT：单向解码器，只看上文（从左到右）。预训练任务是”续写作文”——根据前文预测下一个词。擅长生成文本，适合对话、写作、代码生成等任务。

一句话区别：BERT 是”完形填空高手”，GPT 是”续写作文能手”。

2.5.4 18. ViT (Vision Transformer)

ViT

一句话：把图片切成一个个小方块（patch），把每个小方块当作一个“词”，然后像处理文本一样用 Transformer 处理。

为什么能行？因为注意力机制不在乎输入是文字还是图片像素，只要切成序列就行。数据量够大时，ViT 甚至超越了传统 CNN。

2.6 生成模型 (Generative Models)

2.6.1 19. 生成对抗网络 (GAN)

GAN

一句话：两个网络对抗训练——生成器负责造假，判别器负责验真，互相博弈，最终生成器造的假货连判别器都认不出。

场景：生成逼真的人脸、图像超分辨率、风格迁移、数据增强。

类比：就像造假币的 vs 验钞机，假币越做越真，验钞机越来越厉害，双方共同进步。

2.6.2 20. 变分自编码器 (VAE)

VAE

一句话：把数据压缩到一个有规律的潜在空间里，再从潜在空间还原回来，压缩 + 重建 = 学会数据分布。

场景：图像生成、数据压缩与重建、药物分子生成。

对比：GAN 生成的图像更锐利但训练不稳定；VAE 生成更模糊但训练稳定，且潜在空间有良好的数学结构，可以插值生成中间状态。

2.6.3 21. 扩散模型 (Diffusion Model)

Diffusion Model

一句话：先给图片不断加噪直到变成纯噪点，然后训练网络学会一步步把噪点去掉，从噪点中慢慢还原图像。

场景：AI 画图（Stable Diffusion、DALL·E、Midjourney）。

类比：就像你把一滴墨水滴进水里扩散开，扩散模型学会“倒放这个过程”——从均匀的浑水中一点一点把墨滴“收”回来。

2.7 强化学习 (Reinforcement Learning)

2.7.1 22. Q-Learning

Q-Learning

一句话：维护一张“记分牌”（Q 表），记录在每个状态下做每个动作能拿多少分，选分数最高的动作就行。

场景：简单游戏的 AI、机器人路径规划、迷宫求解。

类比：就像你记住了“在这个路口左转能拿 10 分，右转能拿 5 分”，下次到这个路口你就左转。

2.7.2 23. 深度强化学习 (DRL)

DRL

一句话：状态太多 Q 表存不下？用神经网络代替 Q 表，输入状态，输出每个动作的 Q 值。

场景：Atari 游戏、围棋（AlphaGo）、自动驾驶决策。

对比：Q-Learning 用表格存分数，DRL 用神经网络“猜”分数——状态空间巨大时表格不现实，神经网络可以泛化到没见过的状态。

2.7.3 24. AutoGPT / 自主 Agent

AutoGPT

一句话：让大语言模型自己设定目标、自己拆解任务、自己调用工具、自己评估结果，尽量减少人类干预。

场景：自动调研写报告、自主编程调试、连续执行多步骤任务。

注意：目前自主 Agent 还很不成熟，经常跑偏或陷入循环，但这是 AI 发展的重要方向——从“你问我答”变成“我帮你做”。

2.8 优化与评估

2.8.1 25. 交叉验证 (Cross Validation)

Cross Validation

一句话：把数据分成几份，轮流拿一份当测试集、其余当训练集，多次考试取平均，避免一次考好就膨胀。

最常用的是 K 折交叉验证：把数据分成 K 份，做 K 次训练和验证，取 K 次结果的平均。这样评估结果更可靠，不会因为数据划分的运气成分而偏差太大。

2.8.2 26. 超参数调优 (Hyperparameter Tuning)

Hyperparameter Tuning

一句话：调模型的各种”旋钮”（学习率、树的数量、正则化强度等），找到最佳画面。

类比：就像调老电视的旋钮——亮度、对比度、色调，每个旋钮转一点画面就变，要耐心地调到最佳效果。常见方法有网格搜索（每个旋钮转一圈试一遍）、随机搜索（随机转几次碰运气）、贝叶斯优化（根据之前的结果猜下一个好位置）。

2.8.3 27. 特征工程 (Feature Engineering)

Feature Engineering

一句话：在把数据喂给模型之前，先把”食材”切好、配好、选好，让模型更容易学。

类比：就像做饭——同样的原材料，切配方式不同，做出来的味道天差地别。特征工程包括：特征选择（扔掉没用的食材）、特征构造（把两种食材组合出新味道）、特征缩放（统一量纲，别让盐和水的量级差距太大）。

在传统机器学习中，特征工程做得好，比模型选得花哨更重要。